

A world map with a light blue background, overlaid with a network of glowing lines and nodes in various colors (blue, green, orange, red). The nodes are connected by curved lines, suggesting a global network or data flow. Some nodes are accompanied by small icons like location pins, speech bubbles, and social media symbols.

COVID-19 en Twitter

Transformando datos masivos en Insights de Negocio

DIRECCIÓN DE ESTRATEGIA Y COMUNICACIÓN

PERFIL NO TÉCNICO

Introducción y Enfoque del Proyecto

Analizar un feed masivo y caótico de más de **60,000 tweets en múltiples idiomas**



El Desafío

Más de 60,000 tweets en múltiples idiomas, datos caóticos y sin estructura clara.



El Enfoque Analítico

Ingeniería de Datos en VS Code con Python (Pandas) para limpiar textos, corregir inconsistencias y estandarizar variables geográficas.



El Objetivo

Responder las tres preguntas clave: ¿Dónde ocurre la acción?, ¿Cuándo ocurre?, y ¿Quién está interactuando?

El Dataset

60,160

Tweets

Filas en el dataset

22

Columnas

Estructura rica para análisis

55%

Inglés

33,174 tweets

26%

Español

15,814 tweets

- Distribución idiomática: 33,174 tweets en Inglés (55%), 15,814 en Español (26%), otros idiomas minoritarios.
- Engagement desigual: 50% de tweets con 0 retweets/likes, pero máximo de 23,832 retweets; presencia de influencers y outliers.
- Coordenadas geográficas: 99.97% vacías (solo 19 de 60,000), por lo que se eliminan estas columnas.
- Verificación de cuentas: 90.1% no verificadas; la conversación está impulsada por ciudadanía general, no por instituciones.

Preparacion y Transformación del Dataset

La robustez de cualquier análisis depende directamente de la calidad y estructura de los datos de entrada. Por ello, implementamos un proceso riguroso de limpieza, estandarización y enriquecimiento del dataset original.

1

Gestión de Datos Incompletos

Las columnas de coordenadas geográficas (Lat y Long), con un 99.9% de valores nulos, fueron eliminadas para optimizar el modelo de reporting. Los valores faltantes en variables categóricas como "Tweet Location" y "Tweet Language" se imputaron con "Desconocido", preservando la integridad del registro sin sesgar las métricas.

2

Ingeniería de Variables Temporales

La columna "Tweet Posted Time (UTC)" se transformó a formato datetime, permitiendo la creación de variables clave como "Año-Mes" para análisis de tendencias y "Hora del Día" para identificar patrones de interacción.

3

Estandarización de Ubicaciones

Se desarrolló un algoritmo de mapeo por palabras clave para estandarizar la caótica columna "Tweet Location", transformando texto libre en variables geográficas limpias y reconocibles por herramientas de Business Intelligence, tales como "Ciudad", "País", y "Continente".

4

Creación de Dimensiones de Comportamiento

Para un análisis profundo del usuario, se generaron tres nuevas dimensiones: "Categoria_Influencia" (basada en el volumen de seguidores), "Tiene_Mencion" y "Tiene_Enlace" (indicadores booleanos de interacción), y "Dispositivo_Limpio" (estandarizando las fuentes de los tweets en 5 categorías tecnológicas).

Este proceso transformó un dataset crudo y complejo en una base de datos estructurada y lista para generar insights accionables, permitiendo un análisis multidimensional de la conversación sobre el COVID-19 en Twitter.

¿Dónde ocurre la acción? – Concentración de Mercados Líderes

Métricas Destacadas

4,058

 Estados Unidos

Tweets centralizados. Líder absoluto de la muestra global.

2,528

 España


Tweets registrados. Segundo mercado más activo de la conversación.

La conversación digital no estuvo fragmentada de forma uniforme. Se concentró en un duopolio claro entre **EE.UU. y España**.

Cualquier campaña o monitoreo reputacional debe **priorizar estos dos focos geográficos** para maximizar el impacto y la eficiencia de los recursos.


✔ Visualización principal generada en Tableau y Matplot

Distribución de Tweets por País Estandarizado (Top Mercados)



¿Cuándo ocurre? – El Ritmo de la Conversación

La conversación sobre la pandemia es **cíclica y predecible**. El volumen crece de manera sostenida durante la tarde, alcanzando un pico máximo.



El gráfico de área muestra con claridad el patrón de actividad global a lo largo del día. El volumen escala progresivamente desde la madrugada, con una aceleración notable a partir de las 20.00, hasta alcanzar su **pico máximo a las 23:00**.



La Hora Dorada: Las 21:00 UTC es la ventana horaria idónea para publicar comunicados sensibles y maximizar el alcance orgánico garantizado.

¿Quién interactúa? – La Brecha Cultural y Tecnológica

🇬🇧 Entorno Anglosajón (English)

Fuerte preferencia por el **ecosistema Apple iOS** (iPhone/iPad). Los usuarios anglófonos consumen contenido principalmente desde dispositivos Apple.

🇪🇸 Entorno Hispanohablante (Spanish)

Predominio absoluto del uso de **Android**. La audiencia hispanohablante accede a Twitter mayoritariamente desde dispositivos Android.

Insight de Negocio

Las estrategias digitales **no pueden ser genéricas**. Los entregables visuales y plataformas informativas deben diseñarse bajo un enfoque **"Mobile-First"**, optimizando las interfaces para las diferencias de consumo de ambos sistemas operativos.

⚠ Ignorar esta brecha tecnológica puede reducir significativamente la efectividad de las campañas de comunicación dirigidas a audiencias hispanohablantes.

PERFIL ANGLOSAJÓN (ENGLISH)

Preferencias
iOS




PERFIL HISPANOHABLANTE (SPANISH)

Predominio
Android



Evidencia y Conexión

Tradicionalmente, las redes sociales son percibidas como plataformas para opiniones rápidas y contenido subjetivo. Sin embargo, durante la crisis de la COVID-19, observamos un comportamiento anómalo y maduro en la comunidad digital.



Ante la incertidumbre global y la crisis sanitaria, la audiencia sintió la necesidad imperativa de respaldar y legitimar sus afirmaciones. Los usuarios no solo expresaron sus opiniones, sino que adjuntaron evidencias: artículos periodísticos, hilos científicos, boletines oficiales del Estado o reportes de la OMS.



Compartiendo Evidencia

Anexando enlaces a fuentes fiables como artículos científicos o informes de la OMS.




Debate Dirigido

Utilizando activamente el símbolo @ para interactuar y abrir discusiones con terceros.

Al combinar ambas métricas, se descubre que el tuit estándar de la crisis de la COVID-19 fusionaba **reputación** (a través de enlaces verificables) y **dirección** (mediante el etiquetado a terceros para el debate), marcando un hito en la interacción digital durante una crisis.

Asimetría de Interacción

En Twitter, la conversación sobre COVID-19 siguió una clara **ley de potencia**: unas pocas cuentas concentraron la mayor parte del alcance e interacción.



La asimetría es marcada: los **micro-usuarios** generan casi nulas interacciones por tuit, mientras que las cuentas de **celebridad / institución** disparan los retweets y pueden mover la narrativa a gran escala.

Insight de negocio: para mitigar desinformación o lanzar campañas, el monitoreo debe enfocarse de forma quirúrgica en las cuentas de alto alcance; un solo tuit de este segmento puede superar a miles de usuarios comunes.

En el tramo intermedio, los **micro-influencers** y usuarios activos ganan tracción y actúan como traductores de información: no masifican el mensaje, pero sí lo vuelven creíble y cercano para su comunidad.

Recomendación: priorizar el seguimiento de cuentas de alto impacto y activar micro-influencers para amplificar mensajes clave con confianza local.

Conclusiones y Próximos Pasos

Logramos reducir un dataset caótico a **3 dimensiones clave** que permiten tomar decisiones estratégicas con precisión y agilidad.

Geografía

EE.UU. y España concentran la conversación. Foco dual para cualquier campaña de monitoreo reputacional.

Tiempo

23h UTC es la ventana de máximo impacto. Publicar en este horario garantiza el mayor alcance orgánico posible.

Consumo

iOS domina en inglés, Android en español. El diseño Mobile-First debe adaptarse a cada ecosistema cultural.

Influencers

Las cuentas de tipo "Celebridad/Institución" (>50k seguidores) y los "Micro-Influencers" (5k-50k) monopolizan el impacto y los retweets, mientras que la masa genera ruido pero no tracción

Enlaces de Referencia

83.3% de los mensajes incluyen enlaces web de referencia.

El negocio está obligado a adoptar una comunicación basada en datos